Obliczenia naukowe

Lista 1

Szymon Pestrowicz, 268496

Zadanie 1

	macheps	eps()
Float 16	0.000977	0.000977
Float 32	1.1920929e-7	1.1920929e-7
Float 64	2.220446049250313e-16	2.220446049250313e-16

Liczby te są takie same jak te zawarte w nagłówku float.h języka C. Z kolei precyzja arytmetyki to połowa z macheps. Przykładowo dla Float64 precyzja arytmetyki wynosi 1.11e-16.

	eta	nextfloat()
Float 16	6.0e-8	6.0e-8
Float 32	1.0e-45	1.0e-45
Float 64	5.0e-324	5.0e-324

Liczba MIN_{sub} i eta są do siebie zbliżone, MIN_{sub} dla Float32 podany na wykładzie wynosił 1.4e-45, natomiast dla Float64 wynosił 4.9e-324

Funkcja floatmin(float32) zwraca 1.1754944e-38, natomiast floatmin(float64) zwraca 2.2250738585072014e-308, są to wartości MIN_{nor} podane na wykładzie.

	max	floatmax()
Float 16	6.55e4	6.55e4
Float 32	3.4028235e38	3.4028235e38
Float 64	1.7976931348623157e308	1.7976931348623157e308

Zadanie 2

	Kahan	macheps
Float 16	-0.000977	0.000977
Float 32	1.1920929e-7	1.1920929e-7
Float 64	-2.220446049250313e-16	2.220446049250313e-16

Widzimy, że liczby są takie same, ale w przypadku Float16 i Float64 otrzymujemy przeciwny znak

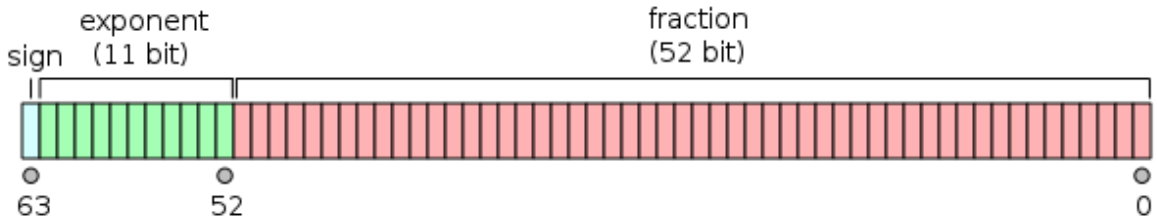
Zadanie 3

Reprezentacja binarna 1:
0011111111110000000000000000000000000000000000000000000000000000

Reprezentacja binarna $1+2^{-52}$:
0011111111110000000000000000000000000000000000000000000000000001

Reprezentacja binarna $2-2^{-52}$:
0011111111111111111111111111111111111111111111111111111111111111

Widzimy, że dwie pierwsze liczby różnią się tylko o 1 na najmniej znaczącym bicie. Łącząc to z obserwacją liczby 3 dochodzimy do wniosku, że ostatnie 52 bity (mantysa) w tej reprezentacji przedstawia ilość (krotność) 2^{-52}.



Ze wzoru $(-1)^{sign}(1.b_{51}b_{50}...b_0)*2^{exponent-1023}$ widzimy, że zmieniając przedział na [2,4] zwiększamy liczbę przez którą mnożymy dwukrotnie, co zmienia rozmieszczenie liczb do k krotności 2^{-51}. Z kolei przejście z naszym przedziałem w dół [0.5,1] zagęszcza rozmieszczenie liczb do $2^{-53.}$

Zadanie 4

Najmniejsza liczba w przedziale 1 < x < 2, taka, że x * (1/x) != 1 to 1.000000057228997. Najmniejsza taka liczba ogółem to 5.0e-324, czyli eta.

Zadanie 5

	Float 32	Float 64
„w przód”	-0.4999443	1.0251881368296672e-10
„w tył”	-0.4543457	-1.5643308870494366e-10
malejąco	-0.5	0.0
rosnąco	-0.5	0.0

Obserwując wyniki w tym zadaniu widzimy, że kolejność dodawania może mieć wpływ na ostateczny wynik. Dodawanie liczb posortowanych w przypadku Float64 zwróciło nam 0.0 dwukrotnie

Zadanie 6

	f(x)	g(x)
$x = 8^{-1}$	0.0077822185373186414	0.0077822185373187065
$x = 8^{-2}$	0.00012206286282867573	0.00012206286282875901
$x = 8^{-3}$	1.9073468138230965e-6	1.907346813826566e-6
$x = 8^{-4}$	2.9802321943606103e-8	2.9802321943606116e-8
$x = 8^{-5}$	4.656612873077393e-10	4.6566128719931904e-10
$x = 8^{-6}$	7.275957614183426e-12	7.275957614156956e-12
$x = 8^{-7}$	1.1368683772161603e-13	1.1368683772160957e-13
$x = 8^{-8}$	1.7763568394002505e-15	1.7763568394002489e-15
$x = 8^{-9}$	0.0	2.7755575615628914e-17
$x = 8^{-10}$	0.0	4.336808689942018e-19

Wiarygodne wyniki zwraca funkcja g

Zadanie 7

Wartość prawdziwa f'(1): 0.11694228168853815

h	przybliżone f’(1)	różnica
2^{-0}	2.0179892252685967	1.9010469435800585
2^{-1}	1.8704413979316472	1.753499116243109
2^{-2}	1.1077870952342974	0.9908448135457593
2^{-3}	0.6232412792975817	0.5062989976090435
2^{-5}	0.24344307439754687	0.1265007927090087
2^{-10}	0.12088247681106168	0.0039401951225235265
2^{-15}	0.11706539714577957	0.00012311545724141837
2^{-20}	0.11694612901192158	3.8473233834324105e-6
2^{-25}	0.116942398250103	1.1656156484463054e-7
2^{-28}	0.11694228649139404	4.802855890773117e-9
2^{-30}	0.11694216728210449	1.1440643366000813e-7
2^{-35}	0.11693954467773438	2.7370108037771956e-6
2^{-40}	0.1168212890625	0.0001209926260381522
2^{-45}	0.11328125	0.003661031688538152
2^{-50}	0.0	0.11694228168853815
2^{-54}	0.0	0.11694228168853815

Dzieje się tak, ponieważ schodzimy już na bardzo małe wartości h, które jest ciężko reprezentować nawet w arytmetyce Float64. Największą dokładność otrzymałem dla $h = 2^{-28}$